第八讲 - 文件读写

张建章

阿里巴巴商学院

杭州师范大学

2022-09

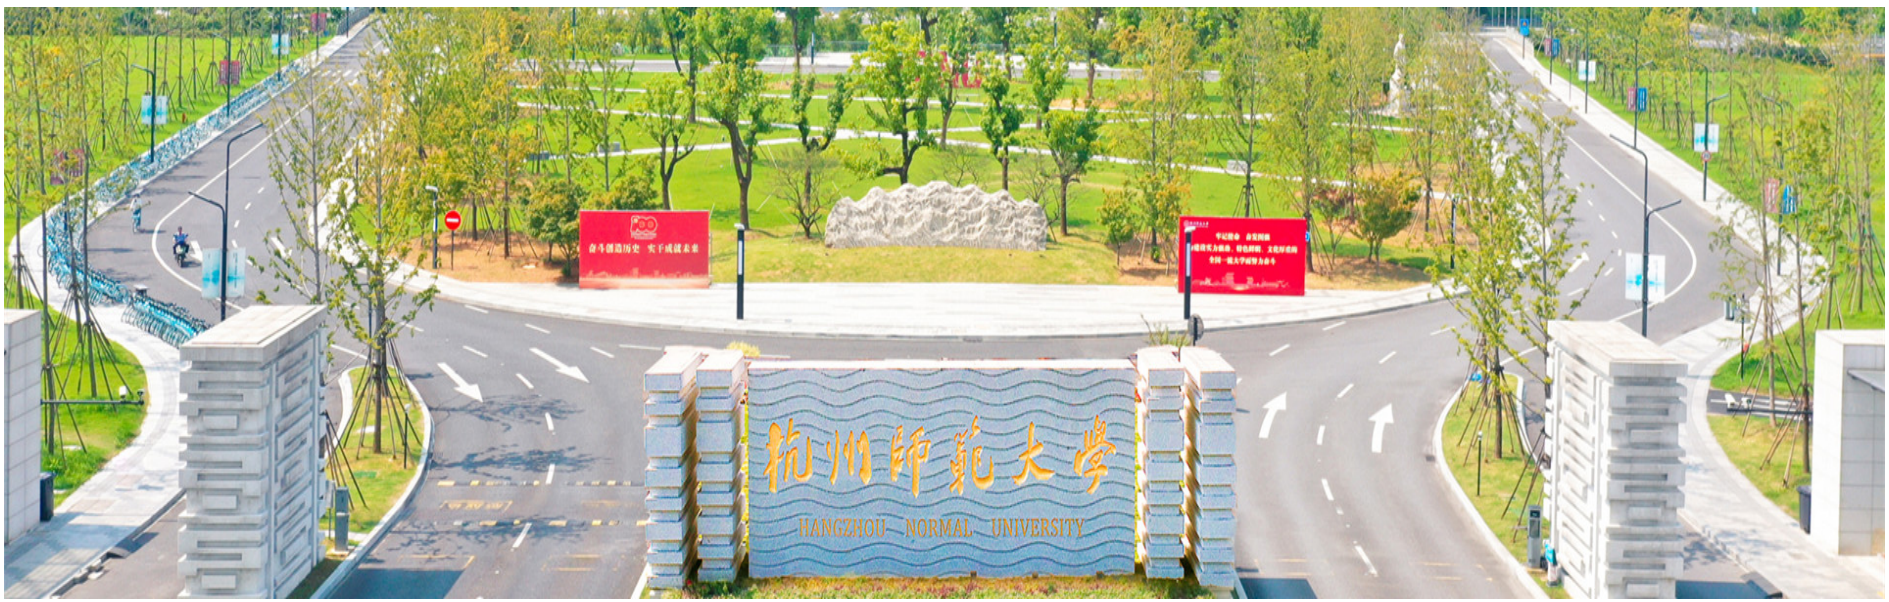

目录 I

本讲主要学习文本文件的打开和读写操作，暂不涉及操作其他类型的文件 (如，图像、音视频)。使用内置函数 `open` 打开文本文件，其用法如下:

```
file_object = open(file_path, open_mode)
```

其中，参数 file_path 表示文件路径，没有默认值，必须提供；参数 open_mode 表示打开模式，默认值为 rt 表示文本只读模式。

```
f = open('./stopwords.txt') # 打开存储停用词表的文件
stopwords_str = f.read() # 读取文件中的全部内容
f.close() # 关闭文件
# 将文件中的内容stopwords_str先去掉一层引号，再作为Python语句运行
stopwords_list = eval(stopwords_str) # 将文件中的内容转化为列表

# with关键字和open配合使用可以避免手动关闭文件
with open('./stopwords.txt') as f:
  stopwords_str = f.read()
stopwords_list = eval(stopwords_str)
```

注意：推荐 `open` 函数和关键字 `with` 配合使用，避免手动关闭文件。

文件路径

绝对路径: 从根目录开始到文件的路径，如:

/home/zjz/Desktop/stopwords.txt (linux)

C:\Users\zjz\Desktop\stopwords.txt (Windows)

相对路径: 从当前目录到文件的路径，如:

./stopwords.txt (linux/Windows，假定当前目录为桌面)

注意：推荐使用相对路径，提高代码的可移植性。如果四六级高频词作业我使用绝对路径，每个同学拿到作业题干后都需要对绝对路径进行修改后才能运行，这样的代码可移植性太差。

打开模式

打开模式参数包含三部分，格式如下：

```
r/w/a t/b [+]
```

第一部分为读写模式，有如下三种选择 (三选一):

r: 只读 (only read)，是读写模式的默认值；

w: 只写，文件不存在则创建，文件存在，则清空已有内容，写入新内容；

a: 只追加写入，文件不存在则创建，文件存在，则在已有内容之后追加写入新内容。

第二部分为文件格式，有如下两种选择 (二选一):

t: 文本格式，是文件格式的默认值；

b: 二进制格式，一般用于打开图片、视频等非文本文件。

第三部分的加号表示在原有基础上可读可写 (可选)

常用的打开模式参数有: rt, wt, at, t 是默认文件格式，可以省略，即，r, w, a。

```
# 读取stopwords.txt中保存的通用英语停用词
with open('./stopwords.txt') as f:
  stopwords_str = f.read()

# 新建领域停用词表，写入三个停用词
with open('./domain_stopwords.txt','w') as f:
  f.write('part\nquestions\nexam') # \n表示换行

# 在新建的领域停用词表中，追加写入两个停用词
with open('./domain_stopwords.txt','a') as f:
  f.write('\nminutes\ncollege') # \n表示换行
```

除上例中常用的三种打开模式参数外，我们看几个复杂例子 (不常用)。rb+ 表示以二进制格式打开一个文件，可读可写，若文件不存在不会创建，wb+，表示以二进制格式打开一个文件，可读可写，若文件不存在则创建一个。

使用 `open` 函数打开文件后，可用下面三个方法读取文件中的内容：

① `read`，它有一个可选非关键字参数 size，指定读取的内容长度，该参数默认值为-1，表示读取文件中的全部内容。

```
# 读取stopwords.txt中的前7个字符，空格和换行符都要计入
# ['i',\n
with open('./stopwords.txt') as f:
  stopwords_str = f.read(7) # f.read(size=7)是错误写法，
  ↪  因为size是非关键字参数

# 读取stopwords.txt中的全部内容
with open('./stopwords.txt') as f:
  stopwords_str = f.read()
```

② `readline`，读取文件中一行的内容，包括换行符在内，它有一个可选非关键字参数 size，指定读取的内容长度，该参数默认值为-1，表示读取一整行内容。

```
# 读取一行内容，['i',\n
with open('./stopwords.txt') as f:
  line = f.readline()

# 读取一行内容的前2个字符，['
with open('./stopwords.txt') as f:
  line = f.readline(2)

# 指定的长度超过一行的长度，只返回一行内容，['i',\n
with open('./stopwords.txt') as f:
  line = f.readline(20)
```

③ `readlines`，读取文件中的全部内容，返回一个字符串列表，文件中的每一行 (包括换行符) 是列表中的一个元素。

```
# ['part\n', 'question\n', 'exam\n', 'minutes\n', 'college']
with open('./domain_stopwords.txt') as f:
  lines = f.readlines()
```

```
# 使用for循环逐行读取内容 (包括每行末尾的换行符)并处理
with open('./domain_stopwords.txt') as f:
  for line in f:
    print(len(line.strip()))
```

注意: read 和 readline 方法返回的是字符串，readlines 方法返回的是字符串列表。

使用 `open` 函数打开文件后，可用下面两个方法把字符串写入文件中：

① `write`，把字符串写入到文件中。

```
# 新建领域停用词表，写入三个停用词
content = 'part\nquestions\nexam'
with open('./domain_stopwords.txt','w') as f:
  f.write(content) # \n表示换行

# 在新建的领域停用词表中，追加写入两个停用词
with open('./domain_stopwords.txt','a') as f:
  f.write('\nminutes\ncollege') # \n表示换行
```

② `writelines`，将字符串列表写入文件，即，使用空字符作为连接符，将一个字符串列表拼接为一个字符串，再将字符串写入文件。

```
lines = ['part\n','question\n','exam']
with open('./domain_stopwords.txt','w') as f:
  f.writelines(lines)

with open('./domain_stopwords.txt','w') as f:
  f.write(''.join(lines))

lines = ['part','question','exam']
with open('./domain_stopwords.txt','w') as f:
  f.write('\n'.join(lines))
```

注意: 没有 `writeline` 方法。

总结

- 使用 with 关键字搭配 open 函数打开文件；
- 读取文件内容，打开模式参数使用默认值；
- 写内容到文件，打开模式参数使用 w 或 a；
- 使用**字符串方法** (以及 join 方法) 搭配文件读写方法进行读写操作；

注意：处理中文文本读写时，请先运行如下两行代码，指定系统编码格式为 UTF-8。

```
import _locale
_locale._getdefaultlocale = (lambda *args: ['zh_CN', 'utf8'])
```

打开文件后可以使用 `tell` 方法查看游标位置，用 `seek` 方法移动游标 (cursor)，这两个方法的单位均为字节 (byte)，一个英文字符占一个字节，一个 UTF-8 编码的中文字符占 3 个字节。

`seek` 方法有两个非关键字参数，offset 指定移动的字节数，没有默认值，whence 指定游标从哪个位置开始移动，默认值为 0，表示从文件头开始移动，另外两个可选值为 1 和 2，分别表示从当前位置和文件末尾开始移动。

```
lines = ['大学','exam','英语考试']
with open('./domain_stopwords.txt','w', encoding = 'utf-8') as f:
  f.write('\n'.join(lines))

# windows系统中，以二进制 (b)方式打开文本文件，
↪  可能会在每个换行符\n前面自动添加一个\r，来表示换行
f = open('./domain_stopwords.txt', 'rb')
f.tell() # 0
f.seek(3) # 3
f.readline() # b'\xe5\xad\xa6\r\n'
type(b'\xe5\xad\xa6\r\n') # bytes
b'\xe5\xad\xa6\r\n'.decode('utf-8') # 学\r\n
```

```
f.tell() # 8
f.seek(3,1) # 11
f.readline() # m\r\n
f.tell() # 14
f.seek(2,2) # 28
f.seek(6,0) # 6
f.readline() # \r\n
f.seek(-5,1) # 3
f.readline().decode('UTF-8') # 学\r\n
# 下面查看文件对象f的一些属性
f.closed # False，文件处于未关闭状态
f.encoding # utf-8，文件编码方式为utf-8，以二进制方式打开文件，
↪  则不存在该属性
f.mode # rb，文件打开模式为二进制只读
f.name # ./domain_stopwords.txt，文件路径
f.close() # 关闭文件，一定要记得关闭文件
f.closed # True，文件处于关闭状态
```

注意: 使用 `open` 函数打开文件，文件读写操作完成后，一定要记得关闭文件，如果你怕忘记关闭，推荐 `open` 函数和 `with` 关键字搭配使用。

内置函数 `print` 不仅能够在屏幕打印输出，还可以将内容写入到文件，如下示例：

```
lines = ['part','question','exam']
with open('./domain_stopwords.txt', 'w') as f:
  for line in lines:
    print(line,end='\n',file = f)

with open('./domain_stopwords.txt', 'r') as f:
  content = f.read() # part\nquestion\nexam\n
```

`print` 函数的 end 参数指定结尾字符，默认值为换行符\n.

使用 `input` 函数接收键盘输入，并写入文件。

```
# 给出一个上联，使用input函数接收键盘输入下联，
↪  并将上下联写入文件duilian.txt
left_text = '南通州，北通州，南北通州通南北' # 东当铺，西当铺，
↪  东西当铺当东西
right_text = input('上联是：{}，请您赐下联：'.format(left_text))
with open('./duilian.txt', 'w') as f:
  print('我的上联是：{}'.format(left_text))
  print(left_text, file = f)
  print('您的下联是：{}'.format(right_text))
  print(right_text, file = f)
```

思考：修改上述代码，使对联在文件中竖排显示 (提示：请使用 zip 和 for 循环)。

文件 grades.txt 中保存的内容如下图所示，请你编程:

① 读取 grades.txt 文件中的内容；

② 解析读取的内容，计算每位同学的平均分；

③ 将计算结果写入 average.txt 文件中，第一列为姓名，第二列为平均分。

姓名	语文	数学
张三	88	64
李四	90	78
王五	65	45
赵六	43	66
冯七	62	56
刘八	90	42
阮九	68	36
陆十	86	46

点我下载 grades.txt 文件 (右键-另存为即可保存到本地)。

```
# 打开文件，读取内容
with open('./grades.txt') as f:
  lines = f.readlines()

# 解析内容，计算平均分
new_lines = ['姓名\t平均分']
for line in lines[1:]:
  l = line.strip().split()
  name = l[0]
  avg = sum(map(float,l[1:]))/len(l[1:])
  avg_str = str(avg)
  new_lines.append(name + '\t' + avg_str)

# 将结果写入文件
with open('./average.txt','w') as f:
  f.write('\n'.join(new_lines))
```

请将文本文件**流水.txt**(点我下载，浏览器中右键-另存为)和**账面.txt**(点我下载，浏览器中右键-另存为)中的内容解析为二维列表。

```
lines = []
with open('./流水.txt') as f:
  for line in f:
    line_list = line.strip().split('\t')
    lines.append(line_list)

data = []
for line in lines[1:]:
  line[-1] = float(line[-1].replace(',',''))
  data.append(line)

print(data)
```

为便于各类文本文件读写，参照上一讲模块与包的内容，我自己编写了一个文件读写 package，可用于读写多种文本文件，如 txt, xlsx, csv 等，安装使用方法如下：

① 点我下载 utils.zip;

② 解压 utils.zip 得到 utils 文件夹，将该文件夹放置到 `anaconda3\Lib\` 中；

③ 开始使用，示例如下

```
# 指定windows平台下Python运行时的默认编码类型为UTF-8
import _locale
_locale._getdefaultlocale = (lambda *args: ['zh_CN', 'utf8'])

from utils.fileUtils import *

lines1 = readExcelToList('./账面.xlsx')
len(lines1) # 查看行数是否与excel文件中的行数相符
lines1[:3] # 查看内容和格式是否与excel中的相符
help(readExcelToList) # 查看readExcelToList函数用法
```

写在课程最后的话

学习这门课程的目的是为了培养**计算思维**，为今后的学习、工作提供一种高效的工具。

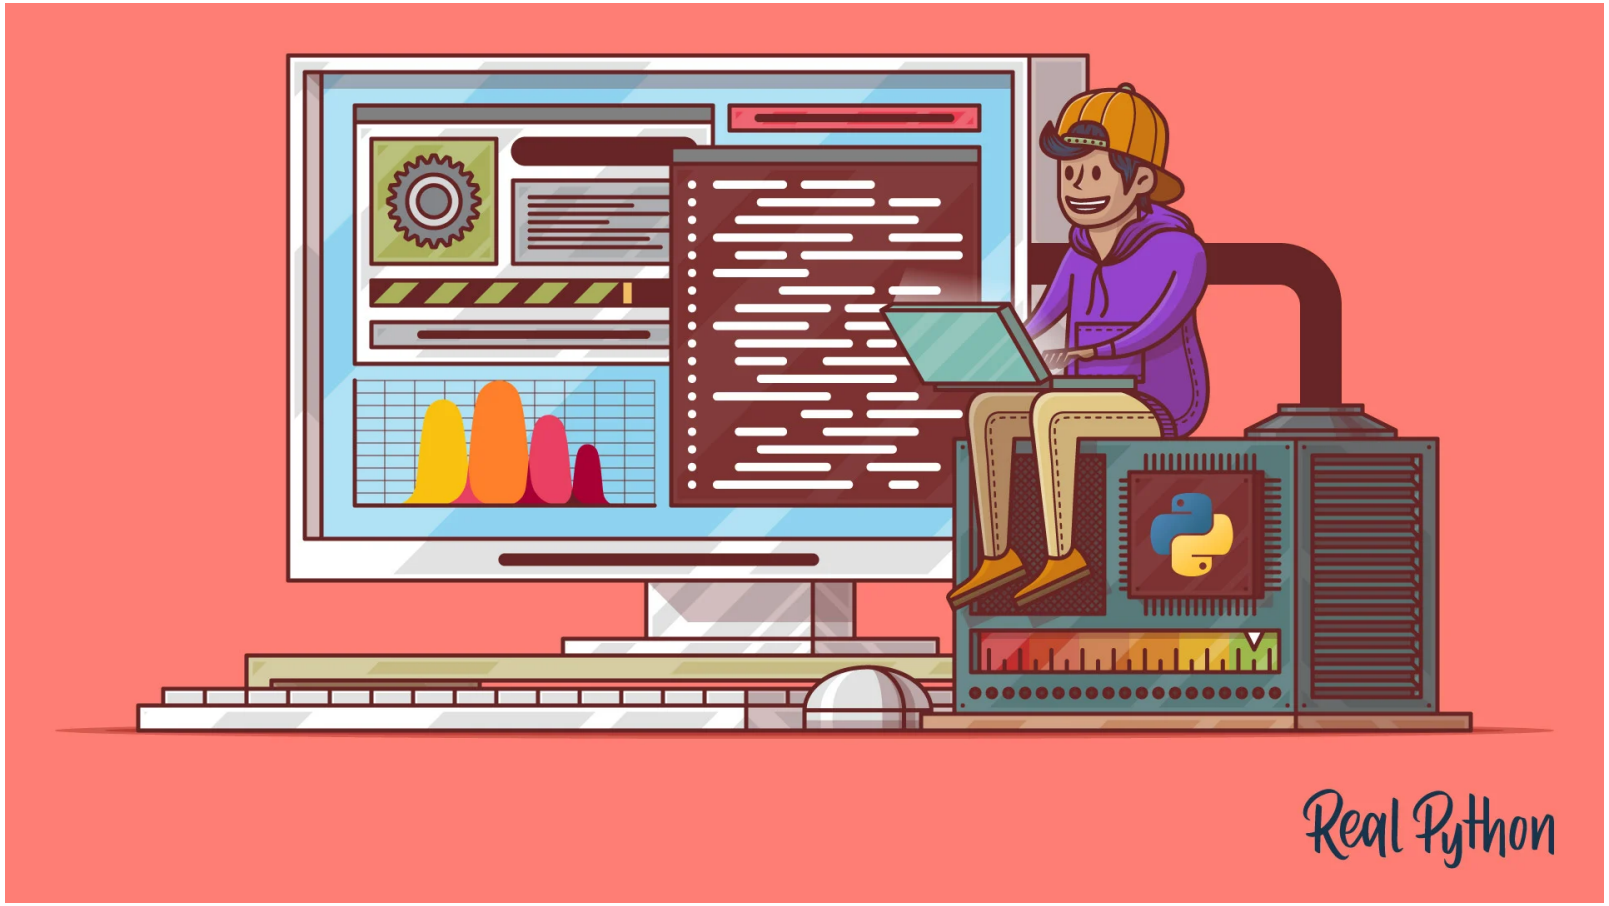

这个任务能用 Python 更高效解决吗，如果能，应该如何**分解问题**，对于分解后的问题，通过查阅互联网**寻找解决方法**，**整合解决方案**。

THE END